


THREAD-Bench

任务类型与知识来源

区分开放型与附件型任务。明确 Agent 执行时的知识来源，以及 Benchmark 构建 Query / Rubric 时的知识来源



名字：

对，End-to-End 有些过度概括，而且和 Handoffs 语义重复。

通常“end-to-end benchmark”暗示从用户输入、工具执行、生成、渲染直到交付结果的完整链路都被覆盖。你的 benchmark 更准确的定位是：

- 评价若干关键中间阶段；
- 评价阶段间的 handoff；
- 检查需求是否持续落实；
- 对比中间产物与最终 deck。

它是 process-aware、long-horizon，但不必宣称完整 end-to-end。

THREAD-Bench: Tracing Handoffs, Requirements, and Execution Across Deck Generation

对应：

- Tracing
- Handoffs
- Requirements
- Execution
- Across
- Deck Generation

这个版本很贴合现有设计：

- Handoffs：Research → Plan → Image → Slide之间的关键handoff；
- Requirements：Query Requirement Manifest 和 case rubric；Query要求在长程执行中的持续保持；
- Execution：真实检索、图片准备、页面检查与修改；最终Deck的知识、全局组织与逐页呈现质量。
- Across Deck Generation：说明考察范围是 deck 生成过程，而不只是成品。中间过程与最终Deck之间的一致性；

第一部分：评测方案设计

一、为什么要区分中间过程与最终产物，以及知识质量与呈现质量

1. 中间过程 vs 最终产物

- 中间过程评测：反映 Agent 主动拆解、调研、规划、工具调用和纠错的长程 Agentic 能力，体现的是整个PPT生成的工作流。 主要关注四类可以从轨迹中直接观察的关系：

观察关系	典型问题
完整性	需要研究的主题、素材和页面是否得到覆盖
时序关系	是否先研究和规划，再进入页面生产
下游使用关系	Research 是否进入 Plan，素材是否真正进入页面
验证闭环	是否形成“发现问题—修改—重新验证”的闭环

- 最终产物评测：过程好不等于最终 PPT 好，例如计划没有执行、内容遗漏或排版失败，因此两者缺一不可。

参考：<https://arxiv.org/html/2603.22744>（long horizon agentic benchmark，用skills要求agent输出中间产物）

2. 知识质量 vs 呈现质量

- 知识质量：PPT 是知识的呈现形式之一，必须保证核心事实、概念和结论正确。
- 呈现质量考察模型将结构化或非结构化知识转化为高质量 PPT 的能力，具体分为多页呈现和单页呈现。
- 分开评价可以避免“视觉精美掩盖事实错误”，或者“知识丰富掩盖结构和排版问题”。

二、各评测模块分别包含什么

1. Intermediate：中间过程

工作流阶段与 Process Rubric 的对应关系

原工作流阶段	Process Judge 中的处理
Material、Research	纳入 R：Material & Research
Deck Planning	纳入 P：Deck Planning
Plan Validation	不单独评分；有校验反馈时，评价 Agent 是否完成修订
Image、Catalog 中与判断相关的部分	纳入 I：Image Asset Preparation
Parallel Slide	纳入 S：Slide Production & Local Verification
Review	预留 V：Deck Review & Revision，目前是否纳入仍待确定

(review部分评测比较复杂，先不考虑)

最后大维度：R、P、I、S 四个阶段，共七条 Rubric

阶段	适用说明
R. Material & Research	无附件时，Material 相关内容记为 N/A
P. Deck Planning	所有任务适用
I. Image Asset Preparation	不需要附件图、搜图或生图时记为 N/A
S. Slide Production & Local Verification	所有页面生产任务适用

参考Page展开为每个页面，每个criterion可以进一步展开为语义单元：

- R01按核心研究主题展开；
- R02按预先标记的高风险事实展开；
- P01按Query Requirement Manifest逐项展开；
- P02按整册叙事和当前plan中的逐页任务展开；
- I01、I02按每个实际图片任务展开；
- S01按当前run实际生成的每一页展开。

展开只增加独立检查次数，不改变criterion本身的评分定义。

2. Final：最终产物（HTML提取内容 与渲染图片）

最终产物分为两个大部分：

- 多页呈现质量（Deck-level）：关注整体故事线、节奏、内容选择、跨页衔接和全局视觉统一。
 - 知识：关注核心知识覆盖、事实与数值正确性。
 - 其他维度（6个）
- 单页呈现质量（Page-level）：关注单页的信息层级、图文关系、排版和技术质量，并根据封面页、过渡页、内容页和结尾页区分标准。

2.1多页与单页呈现质量（知识转化与展现能力）

这部分考察模型如何将获取到的知识转化为演示文档：

多页呈现质量

Deck关注整套PPT，所有criterion必须映射到以下六个维度之一：

1. 受众与沟通目标适配；
2. 内容选择与信息密度；
3. 叙事结构与章节过渡；
4. 节奏篇幅与冗余控制；

5. 跨页语义一致性；

6. 全局视觉一致性。

知识checklist先形成一个独立的知识维度，再与上述六个Deck维度一起聚合。因此，当前Deck由**六个呈现维度 + 一个知识维度**组成。

Deck必须检查当前run生成的全部页面，不允许抽样。若case要求固定页数，则页数要求由独立criterion检查；全局评测范围仍以实际生成页面为准。

1.知识质量（事实与逻辑）

知识质量须有明确的来源或锚点，主要包括：

1. 文章或其他形式的附件材料（Material）；
2. 网站或者其他权威性来源；
3. 已有的优质 PPT 参考；
4. 已有 Benchmark 中整理好的 Query 和 Rubric。

针对不同任务，知识的考察重点不同：

- **开放研究型任务**：Query 较短，以 Research 和 Plan 为主。知识由 Agent 自主搜索与整理，重点考察最终 PPT 对核心知识的覆盖和正确性。
- **附件材料型任务**：提供长文本、数据或其他材料。知识主要来自用户材料，重点考察 Agent 是否忠实、完整地提取并呈现在 PPT 中。

2.关注整套 PPT

受众适配、内容选择、叙事结构、篇幅节奏、跨页衔接和全局视觉一致性。

单页呈现质量

关注每一页的信息层级、视觉编码、构图排版、字体颜色和技术完整性。


其核心是通过合理的叙事、页面分配、视觉编码和排版，将知识有效传递给目标受众。

Page关注单页表现，所有case-specific Page criterion必须映射到以下五个维度之一：

1. 信息层级与密度；
2. 图文关系与视觉编码；
3. 构图、对齐、排版、留白与平衡；
4. 字体、颜色、对比与可读性；
5. 技术完整性与素材质量。

Page采用“criterion × 实际页面”的独立请求：当前run生成多少个canonical pages，就为每个Page criterion执行多少次适用性判断和评分。每次只输入当前页证据，不能先形成整套印象再复制分

三、 rubric评分设计及评测流程



1. 整体rubric架构

采用“通用维度+任务专属 Rubric（Case-specific）”，既保证不同任务可以横向比较，也保证特定任务的评分足够准确。

基于通用的维度去设计 Case-specific rubric，最后用来评测的只有 Case-Specific rubric。

- 通用维度定义benchmark要评价的能力边界；
- 每个case根据Query、材料和任务特征编写具体criterion；
- 每个criterion必须明确映射到一个通用维度；
- 实际Judge只使用Case-specific rubric；
- 聚合时先在维度内平均，再在维度之间聚合，不能把所有criterion跨维度平摊。

2. 评测输入

不将所有数据无差别输入评测器，而是根据维度选择输入、按任务最小必要范围选择输入。这里减少的是**无关文件数量**，不是压缩高信息内容。：

- 中间过程质量：输入 `plan.md`、`research.md`、trajectory 和检查记录；
- 知识质量：仅输入全部 HTML 提取内容；
- 多页呈现质量：输入全部 HTML 提取内容和全部渲染图；
- 单页呈现质量：输入当前页 HTML、当前页渲染图和页面类型。

2.1 Intermediate输入

- R：Query、研究正文、必要研究trace和Plan；
- P：Query、Plan以及当前规划单元所需的完整研究/资产证据；
- I：当前图片任务对应的需求、搜索/生成trace、catalog、资产和实际使用页面；
- S：当前页面对应的Plan、Slide trace、HTML、渲染记录与诊断图。

2.2 Knowledge输入

知识层只输入：

- Query / instruction；
- 全部HTML提取内容。

知识层不输入渲染图。

2.3 Deck输入

Deck维度	输入
受众与沟通目标适配	全部HTML提取内容
内容选择与信息密度	全部HTML提取内容 + 全部渲染图
叙事结构与章节过渡	全部HTML提取内容
节奏篇幅与冗余控制	全部HTML提取内容
跨页语义一致性	全部HTML提取内容
全局视觉一致性	全部渲染图

2.4 Page输入

每个逐页请求只输入：

- 当前页HTML提取内容；

- 当前页渲染图；
- 当前页面类型。

3. 可选Preaudit

原因：发现judge model对于审美、整体等这种需要模型自己分析给分的rubric，给分容易偏高，或者理由和给分不一致

所以采用先用一个preaudit model（目前用的gemini-3.1-pro-preview），先对输入评测内容（不给rubric）直接检查分析缺陷

这个是个可选项，目前发现加上这个分数确实会更准一些

Final可以开启Preaudit：

1. Preaudit先检查整套最终产物；
2. 只记录检测到的内容或视觉缺陷；
3. 正式Judge只接收与当前criterion相关的缺陷，不接收完整预审分析；
4. Preaudit不直接决定分数，正式Judge仍须根据criterion证据和anchor完成判断。

Preaudit是可选项，不改变Rubric本身的评分定义。

4. 评分分数设计

分两类分数：

- 确定性的评分点：要么有要么没有：0/1
 - 知识层的checklist也算在这里
- 其他：0/0.5/1

不能让judge先给分数再给理由，这样我发现理由是准的，但分数偏高 =>

Judge不先给一个分数再补理由，而是：

1. 阅读当前单元的完整证据；
2. 对每个评分anchor给出是否匹配及理由；
3. 形成证据和缺陷分析；
4. （代码）根据唯一命中的anchor派生 `0 / 0.5 / 1` 或 `0 / 1`。

3.1 知识层评分法

将知识拆解为独立、原子的 Checklist，采用 0 / 1 二元评分。

3.2 多页与单页评分法

- 确定性要求采用 0 / 1 评分；
- 主观质量要求采用三档评分：
 - 1分：优秀；
 - 0.5分：基本可用，但存在局部问题；
 - 0分：存在严重问题。

3.3 N/A语义边界

N/A 只表示Query语义上不要求当前对象或过程，例如没有科学示意图的页面不适用“科学示意图结构” criterion。

以下情况不能判为 N/A：

- Query明确要求，但模型没有生成；
- 过程应该发生，但证据缺失；
- 资产任务规划后没有执行；
- 页面或中间产物遗漏。

适用单元缺失应按anchor评分。 N/A 单元不进入平均，也不触发缺陷扣分。

3.3 基础分数聚合

同时设置必要的封顶规则，例如最终产物完全无法渲染或内容严重跑题时，对总分进行限制。

目前最终只输出两组总分，二者不再合并：

- final_output_case_specific
- intermediate_case_specific

整体顺序是：

原子单元/页面评分 → criterion平均 → 小维度原始分 → v004重大缺陷扣分 → 组内维度聚合 → Final组级衰减 → 输出两组总分

1. 单元到criterion

对于展开型criterion (c)：

$$C_c = \frac{1}{|U_c|} \sum_{u \in U_c} s_u$$

其中, (U_c)只包含适用单元; N/A 不进入分母。

2. Criterion到小维度

每个criterion只能属于一个维度。当前维度内criterion等权:

$$D_d^{raw} = \frac{1}{|C_d|} \sum_{c \in C_d} C_c$$

3.1.1 最终产物分数

设:

- K : Knowledge 维度分
- $Deck$: 原 Deck-level 维度分
- P : Page-level 维度分

最终产物总分:

$$Final = 0.5 \times Deck + 0.5 \times Page$$

Deck-level

$$Deck_{raw} = \frac{D1 + D2 + \dots + D6 + K}{7}$$

之后根据后面新增的 defect policy 扣分机制得到最终分数 $Deck$ 。

Knowledge:

checklist多少条就等权平均

$$K = \text{mean}(K1, \dots, Km)$$

m是当前这个case的knowledge checklist中的数量

其他维度:

同knowledge, 还有共 5 个 Deck criterion, 也是维度内评分点先求平均, 得到每个维度分

Page-level

共5个维度，每个维度内部所有case criterion分数取平均，每个 criterion 都会产生 页面数 个独立页面结果。

对于第*i*个维度的第 *j* 个 Page criterion：

$$Page_{ij} = \frac{\sum_{\text{适用页面}} Page_{ij,p}}{\text{适用页面数量}}$$

然后该维度分数

$$Page_i = \frac{\sum_{\text{所有评分点}} Page_{ij}}{\text{该维度在当前case的criterion数量}}$$

N/A 页面不进入分母。

再对 5 个 Page criterion 等权平均：

$$Page_{\text{raw}} = \frac{1}{5} \sum_{j=1}^5 Page_i$$

随后再执行 defect 扣分，得到最终的 *Page*。

Final组级最弱维度衰减

为避免一个明显短板被其他高分维度完全平均掉，Deck和Page各自只执行一次：

$$G_{\text{effective}} = G_{\text{base}} \times [1 - \alpha(1 - G_{\text{min}})]$$

当前：

$$\alpha = 0.3$$

其中 *G_{min}* 为当前组内最低小维度分。该衰减只用于Final的Deck和Page，Intermediate不执行。

4.1 中间产物分数

中间产物有四个维度：

- Research
- Plan
- Image
- Slide

当前各组 criterion 数量为：

维度	子维度数量	组内聚合
Research	2	两个 criterion 等权
Plan	2	两个 criterion 等权
Image	2	两个 criterion 等权
Slide	1	单个 criterion

类似Page评分方式：

1. 每个展开的语义单元先独立评分：例如 S01 是逐页平均、I02 是逐图片任务平均。
2. 再在子维度（目前这个动物罗盘的case是一个子维度内只有一个criterion）内等权平均。
3. 子维度 criterion 平均聚合为 4 个维度。

$$\text{Research} = \text{mean}(R01, R02)$$

$$\text{Plan} = \text{mean}(P01, P02)$$

$$\text{Image} = \text{mean}(I01, I02)$$

$$\text{Slide} = S01$$

4. 对四个维度分执行重大缺陷扣分。

最后四个维度之间没有显式特殊权重，采用等权平均：

$$\text{Intermediate} = \frac{\text{Research} + \text{Plan} + \text{Image} + \text{Slide}}{4}$$

四个维度正常情况下各占 25%；原有 N/A 排除规则保持不变。

因此正常情况下每个维度权重都是 0.25。

注意：如果某个维度的所有 criterion 都是 N/A，如生图任务：例如完全没有图片任务导致 Image 整组无适用分数

- 如果query中没有明确要求是否要生图/这个case不需要：那么该组会被排除，不算分，剩余三个维度重新等权
- 如果query中明确要求/这个case需要：直接算0分

5. 为了修复分数偏高区分度小的问题，在基础维度分的基础上增加扣分制

扣分是在前面计算完原始平均分之后执行的，而不是修改 Judge 给出的单点分数。

注意：

1. 不要修改评分点具体内容，只需要加一个标签
2. 对于缺陷等级的选取要合理，不要大部分都打重大或者致命等级，要分析具体的评分内容，严谨一点，对真正重要的评分点才打对应的标签

v004 对维度分进行扣分

在设计rubric的时候，对每个评分维度加一个标签："defect_level"标记该维度分数对整体的影响等级，分普通、重大（、致命）

扣分事件触发：

Page 的扣分事件以“单个页面”为最小单位，Intermediate 展开维度以“单个语义单元”为最小单位，而普通 Deck criterion 以 criterion 为最小单位。

- If "defect_level" == 普通：只参与平均，不额外扣分。
- Else if "defect_level" == 重大：如果该评分维度的有一个最小单位的分数=0.5，对应维度总分就扣0.1，0分就扣0.2。触发几个扣几次，但控制一个扣分上限（目前设置的是最多扣0.5）
- N/A 不平均、不扣分。（目前是这样的，是不是后面要调整，还是0分，或者query中强制要求有无？）

对知识层的checklist不需要，不用加这种扣分制(因为感觉知识层的分数已经很有区分度也够低了)

~~v005（目前没有执行了，感觉没必要）~~

先执行与 v004 相同的重大扣分，再执行致命缺陷乘法衰减：

- 致命单点为 0.5：维度分乘 0.65。
- 致命单点为 0：维度分乘 0.3。
- 多个致命缺陷连续相乘。
- 最终截断到 $[0, 1]$ 。

例如某维度原始分为 0.9：

- 发生一个重大 0.5： $0.9 - 0.1 = 0.8$
- 再发生一个致命 0.5： $0.8 \times 0.65 = 0.52$

在大维度Deck/Page上执行乘法衰减

因为发现之前比如Page的其中一个维度分数确实降下来了，但是6个维度计算完平均值之后整个Page分数又偏高了，导致分数该低的还是没有，区分度还是没有打开，

完成维度级扣分后，Deck 和 Page（统一用G代替）分别找出自己的最低小维度分：

$G_{\min}$ = 组内最低维度分

关键是公式需要这样定义：

$d = (1 - G_{\min}) \times \alpha$

这里的 d 是“衰减量”，实际乘数应为(目前 $\alpha = 0.3$ ，之前试过0.5不太行)：

$M = 1 - d = 1 - \alpha(1 - G_{\min})$

所以Deck和Page各自乘上前面的M, 最终：

$G_{\text{final}} = G_{\text{base}} \times M$

这个机制的作用是：当 PPT 存在明显短板时，不能完全依靠其他高分维度把问题平均掉；但也不会因为一个局部问题直接把整套 PPT 判成低分。

codex还推荐加一个触发阈值，避免最低维度只是略低也处罚整组：

(目前没有采用/其实相当于 $\tau = 1$)

$r = \max(0, \frac{\tau - G_{\min}}{\tau})$

$G_{\text{final}} = G_{\text{base}} \times (1 - \alpha r)$

建议初始参数：

- 弱维度阈值 $\tau = 0.6$
- 最大衰减系数 $\alpha = 0.5$
- Deck、Page 分别只乘一次
- N/A 维度不参与 $G_{\min}$

对应效果：

最低维度 \$G_{\min}\$	最终乘数
≥ 0.6	1
0.45	0.875
0.3	0.75
0	0.5

聚合顺序应当是：

代码块

```
1 criterion 原始评分
2 → v004 普通/重大扣分
3 → 维度内聚合
4 → 得到 Deck_base / Page_base
5 → 根据各自最低维度做一次乘法衰减
6 → Final = 0.5 × Deck_final + 0.5 × Page_final
```

四、案例演示：动物环境罗盘 PPT

📖 动物环境罗盘 V2.0

以制作一份25页科普 PPT 为例：

- **中间产物：**检查模型是否提前将25页合理分配给三种罗盘，调研是否覆盖复杂的生物机制，生图 Prompt 是否科学。
- **知识：**通过 Checklist 检查“是否准确说明太阳罗盘依赖生物钟”等具体知识点。
- **多页呈现：**检查25页是否形成“导入—机制—对比—总结”的完整教学主线，章节篇幅是否合理，前后内容是否一致，受众，风格等。
- **单页呈现：**分别评价封面页、机制讲解页和六列表格页的信息层级、图文匹配与排版质量。

五、方案的价值与意义

- **评测长程能力：**让 Agent 的状态保持、工具执行和纠错能力真正可量化。
- **定位问题：**不再只给一个模糊总分，而是明确指出问题来自调研、知识、多页组织还是单页呈现。
- **避免相互掩盖：**防止知识质量和视觉呈现相互掩盖。
- **普适与高复用：**适配主题生成、研报生成、附件转 PPT 和现有文档改写等任务；通用维度和知识 Rubric 可以跨任务复用。
- **反哺模型训练：**具体维度的得分可以指导 Agent 的定向优化和奖励设计。

六、核心总结

这套 Benchmark 首先区分“中间产物”与“最终产物”。

最终产物进一步分为：

- 多页呈现质量；
- 单页呈现质量。

它不仅是在给“PPT 做得好不好”打分，而是在给 Agent 出具一份覆盖执行过程、知识正确性、整体组织和单页呈现的全链路体检报告，明确解释它为什么成功、在哪一步失败，以及后续应该如何优化。

1. 将Query要求、事实、图片任务和页面拆成可核验单元；
2. 依据证据和anchor独立评分；
3. 按criterion和维度逐级聚合；
4. 用v004机制惩罚重复出现的重大缺陷；
5. 用 $\alpha=0.3$ 的组级衰减防止Final明显短板被平均掉；
6. 分别输出中间过程分和最终产物分。

第二部分：Rubric维度设计

Rubric 采用 0-1分制（0分最差，0.5分及格，1分完美 / 确定性的就用0，1）

每一个维度在具体的case中还是要用case specific的形式展现的。

最能体现long-horizon agentic ability的不是产物文件是否存在，而是以下handoff是否成立：

代码块

- 1 Query / Material
- 2 → Research evidence
- 3 → Executable Deck Plan
- 4 → Image tasks and assets
- 5 → Slide construction
- 6 → Real render inspection and repair

Process Rubric维度（参考LH-Bench的 Process Judge）

ID	Rubric	主要评价内容
R1	研究覆盖与证据进入规划	Query 中需要研究支持的主题是否得到覆盖，研究证据是否真正进入整册或逐页计
R2	关键证据核验与不确定性处理	关键事实是否有来源，冲突、不确定或构造信息是否得到记录和标识
P1	Query 硬性要求的规划覆盖	页数、语言、指定内容、必需页面和视觉形式等硬性要求是否在计划中有明确落点
P2	整册规划的可执行性与叙事组织	章节和页面任务是否清楚，证据、图片和视觉形式是否分配到具体页面，计划能否 Agent
I1	搜图关键词与生图 Prompt 的任务匹配	图片获取方式、搜索关键词和生成 Prompt 是否准确对应页面需求
I2	图片结果筛选、调整与最终使用	Agent 是否检查图片结果，在不符合需求时调整，并将最终素材用于对应页面
S1	基于真实渲染的单页检查与修复闭环	Slide Agent 是否查看真实渲染图，发现问题后修改并重新渲染确认

其中最能体现 long-horizon agentic ability 的不是单个文件是否存在，而是以下跨阶段交接：

- Research → Plan
- Plan → Image / Slide
- 图片需求 → 素材获取 → 页面使用
- 页面制作 → 真实渲染 （→ 修改 → 再次验证）

维度一：R：材料理解与研究

对应阶段：Material / Query → Research → Plan

其中 Material 子维度仅在存在附件时使用，不存在就是 N/A ，不算作分母。

评测目标

目标是形成完整、可追溯、区分来源类型、保留冲突与不确定性、能被下游规划使用的知识底稿。

重点检查：

- Query中需要研究的主题是否覆盖；
- 关键事实、数据、年份、案例和引用是否有来源；
- 高风险事实是否经过权威或多源核验；
- 冲突和不确定性是否被记录并传递到Plan；
- Research证据是否真正进入Deck或逐页规划。

重点不是“搜索了多少次”，而是：

代码块	Query / 附件
2	→ 提取事实和需求
3	→ 必要的外部核验
4	→ 区分材料事实、外部补充和不确定信息
5	→ 形成知识底稿
6	→ 被 Deck Planning 实际使用

评估项	评测输入	评什么/定义	1分 (Excellent)
R1. 研究覆盖与证据进入规划	主要文件： research/material.md（有附件时）、research/research.md、research/knowledge-brief.md、plan/deck.md、plan/pages.json、plan/slide_NN.md。 辅助证据： _trace/ 中 Research Agent 的搜索、网页读取和附件解析记录。 **预先提供：** Query 研究主题列表、研究证据及来源、Research→Plan 映射。	检查 Query 中需要 Research 支持的核心主题是否得到覆盖；关键事实、数据、引文和案例是否具有来源；研究结果是否真正进入整册或逐页计划，而不是只停留在研究文档中。按当前文档定义，有附件时使用；无附件时记为 N/A。	同时满足：1. 所有核心研究主要内容；2. 关键数据、事实实例具有可追溯来源；3. 研究底证据明确进入 deck.md、page_slide_NN.md；4. 没有出现大划无关的研究内容；5. 有附件的关键事实被纳入研究底稿。
R2. 关键证据核验与不确定性处理	research/material.md、research/research.md、research/knowledge-brief.md、plan/deck.md、plan/slide_NN.md；_trace/ 中 Research Agent 的检索与网页读取记录。	不评价最终 PPT 中事实本身是否正确，而是评价研究过程是否对明确数字、年份、排名、政策、研究发现等关键事实进行来源核验；是否记录和处理来源冲突；是否明确标识无法确认、估算或人为构造的信息。	同时满足：1. 所有预先标记的有明确来源；2. 高风险事实有多来源支持；3. 冲突信息说明本及原因；4. 无法确认的信息确定、估算或 illustrative；5 没有把未确认信息包装成确定

可以预先提取整理：

A. query研究覆盖表

提前对query预处理，抽成一个个要求字段，例如：

代码块	
1	[
2	{
3	"requirement_id": "Q1",
4	"text": "介绍故宫的建立历史",
5	"research_relevant": true
6	},
7	{
8	"requirement_id": "Q2",
9	"text": "解释故宫的空间秩序",
10	"research_relevant": true
11	},
12	{
13	"requirement_id": "Q3",

```

14     "text": "整体使用故宫红",
15     "research_relevant": false
16 }
17 ]

```

其中 `research_relevant` 可以由模型自动标注，再进行简单人工检查。它只区分：

- 需要事实、数据、案例或来源支持；
- 属于格式、页数、视觉样式等非研究要求。

B. 证据来源表

从中间产物（`research/material.md`，`research/research.md`，`research/knowledge-brief.md`，Research Agent 的 `web_search` / `web_extract` 轨迹）中提取，如：

代码块

```

1  {
2    "evidence_text": "紫禁城以南北中轴线为核心",
3    "research_path": "research/knowledge-brief.md",
4    "source_records": [
5      {
6        "source_url_or_material": "...",
7        "source_span": "..."
8      }
9    ],
10   "source_present": true
11 }

```

C. Research → Plan 使用表

这个映射应在运行后，从以下文件中提取：

代码块

```

1  research/knowledge-brief.md
2  plan/deck.md
3  plan/pages.json
4  plan/slide_NN.md

```

得到例如：

代码块

```

1  {
2    "evidence_text": "紫禁城以南北中轴线为核心",

```

```

3  "research_span": "...",
4  "plan_matches": [
5    {
6      "path": "plan/slide_04.md",
7      "text": "右侧使用故宫平面图解释中轴线和前朝后寝"
8    }
9  ],
10 "used_in_plan": true
11 }

```

如果 Skill 中已经使用 `evidence_id`，可以确定性映射；如果没有，则做语义匹配，并保留两边的原文 span 供 Judge 查看。

维度二：P：整册规划、逐页编排与计划校验

Deck Strategy, Orchestration and Plan Validation

对应阶段： Research / Query → Deck Planning → Plan Validation

评测目标

目标是将Query和研究底稿转化为可执行的Deck生产计划。

重点检查：

- 语言、页数、受众和其他硬性要求；
- 整体叙事与章节关系；
- 每页功能、核心信息和视觉表达；
- 证据、数据和素材的逐页分配；
- 高风险页和特殊页；
- Image与Slide Agent的任务边界。

评价 Orchestrator 是否在页面生产前，将 query 和研究底稿转化为一份可执行、完整且经过校验的 Deck 生产计划。

应覆盖：

- 受众、讲者和预期听众行动；
- 语言、页数和硬性要求；
- 整体叙事结构和章节关系；
- 每页的功能、核心信息和构图类型；

- 数据、证据和素材的逐页分配；
- 全局视觉系统；
- 特殊页和高风险页；
- 校验错误的修复；
- 后续 Image 与 Slide Agent 的清晰任务边界。

评估项	评测输入	评什么/定义	1分 (Excellent)	0.5分 (Acceptable)	
P1. Query 硬性要求的规划覆盖	Query Requirement Manifest、plan/deck.md、plan/pages.json、plan/slide_NN.md。	Judge 只进行要求与计划之间的字段或证据比对，不自行判断“什么内容更合适”。检查页数、语言、指定主题、必须覆盖的内容、必须包含的页面、指定素材或可视化形式，以及明确要求的结尾或讨论内容，是否在计划中有明确落点。	Query 中所有硬性要求均可映射到：1. 一个明确的 slide_id；或2. 一个明确的 deck-level 设计规则。	**不适用。**该项采用 0/1 二值评分。	任意情况：糊损成；突。
P2. 整册规划的可执行性与叙事组织	主要文件：plan/deck.md、plan/pages.json、plan/slide_NN.md、research/knowledge-brief.md、assets/catalog.md。辅助证据：_trace/ 中 Orchestrator 的规划与任务派发记录。**预先抽取：**每页是否存在页面任务、核心信息、视觉表达、证据或素材分配及对应原文。	评价规划是否能够实际指导后续 Slide Agent，而不是检查是否存在固定字段。主要检查整册章节和信息推进、每页任务和核心信息、数据和图片需求的逐页分配、页面重复或断裂，以及 Slide Agent 是否需要重新承担 Research 或整册 Planning。	同时满足：1. 整册具有明确的开场、展开、综合和结尾逻辑；2. 各章节具有清楚功能，章节之间存在可理解的推进关系；3. 绝大多数内容页能识别出明确的页面任务、核心信息和主要视觉表达；4. 关键证据、数据和图片需求已经分配到页面；5. 特殊页或复杂页有足够实施说明；6. 后续 Slide Agent 不需要重新承担 Research 或整册 Planning 工作。	具备基本规划，但存在以下部分不足：1. 有基本页序和章节结构；2. 多数页面有主题，但部分页面只有标题或内容清单；3. 证据、视觉形式或素材安排不够明确；4. 存在少量页面功能重复、前后跳跃或信息负载失衡；5. Slide Agent 仍需要补充少量规划判断。	出现是页面制不清有页必须织可

维度三：I：图片资产准备 Image Asset Acquisition and Catalog Integrity

对应阶段：Image Requirement → Search / Generation → Inspection → Selection → Usage

适用性： 仅在计划需要webfetch获取外部图片、附件图片或生成图片时适用；合法的纯排版、代码图表任务可标记 **N/A** 并重新归一化权重。

评测目标

仅在Query或Plan需要外部图片、附件图片或生成图片时适用。

重点检查：

- 获取方式是否与主体和用途匹配；
- 搜索关键词或生成Prompt是否可执行；
- 具名真实对象是否优先采用真实素材；
- 结果是否被检查，不匹配时是否调整；
- 资产是否映射并实际进入目标页面；
- SVG、图片结构、清晰度和重复问题是否被识别；
- 来源、用途、页面与裁切方案是否可追溯。

评价 Agent 是否根据内容语义选择正确的资产来源，并形成可追溯、可使用、无污染的素材管线。

重点包括：

- 附件图、真实搜索图和生成图之间的选择是否合理；
- 具名人物、地点、产品是否优先使用真实素材；
- 非特定氛围、概念性画面是否合理使用生成图；
- 计划中的资产需求是否得到覆盖；
- 图片是否有效、清晰、无明显重复，特别关注图片结构，特别是svg图结构乱、差很容易影响整体视觉观感；
- 来源、用途、页面和裁切方案是否被记录；
- 无效探测图、临时图和未使用图是否被隔离；
- Catalog 是否在 Slide Agent 使用前形成。

评估项	评测输入	评什么/定义	1分 (Excellent)	0.5分 (Acceptable)
I1. 搜图关键词与生图 Prompt 的任务匹配	页面图片需求： plan/pages.json、 plan/slide_NN.md 、 assets/ catalog.md。实际 图片指令：_trace/ 中 Image Agent 的 image search query 和 image generation prompt、 assets/ catalog_image_NN .md。	检查搜图关键词或生图 Prompt 是否对应页面所需主体、地点、事件、视角、场景、内容、构图、风格和裁切用途；同时检查图片来源策略是否合理：具名人物、地点、产品和事件优先真实图片，概念性或氛围性内容可以生图，数据图和结构图不应被装饰图替代。	同时满足：1. 所有关键图片任务均选择正确的获取方式；2. 搜图关键词或生图 Prompt 与页面需求高度对应；3. 具名主体没有被模糊或错误替代；4. Prompt 对主体、画面用途、构图和风格提供足够约束；5. 不存在明显与页面无关的宽泛搜索。	大部分关键词或 Prompt 能对应页面需求，但存在以下情况：1. 部分任务过于宽泛；2. 缺少视角、场景或构图约束；3. 个别任务的搜索与生图策略选择不理想；4. 不影响主体匹配，但可能导致结果不稳定。
I2. 图片结果筛选、调整与最终使用	_trace/ 中连续的图片搜索或生图调用、 assets/ catalog_image_NN .md、 assets/ catalog.md、 assets/<image>、 plan/slide_NN.md 、 slides/ slide_NN.html。	检查以下流程是否成立：图片需求→搜索或生成→检查结果→必要时调整关键词、Prompt 或来源策略→选择最终图片→分配并用于对应页面。第一次结果已经满足要求时，只需要有明确检查记录，不强制进行二次搜索。	同时满足：1. 最终选中的图片与原页面需求对应；2. 图片不满足需求时，Agent 针对具体问题调整关键词、Prompt 或来源策略；3. 调整不是简单重复原查询；4. 最终图片明确分配到对应页面；5. 页面实际使用该图片，或者计划明确改为无图方案；6. 没有大量无关搜索或重复生成。	最终获得并使用了基本匹配的图片，但存在以下情况：1. 筛选依据不清楚；2. 图片不理想时只进行简单重复查询；3. 部分最终素材与页面需求之间的映射不明确。

维度四：S：逐页制作与单页渲染自检 Slide Construction and Local Render Verification

对应阶段：Write → Parallel Slide

评估项	评测输入	评什么/定义	1分 (Excellent)	
S1. 基于真实渲染的单页检查与修复闭环	plan/slide_NN.md、 slides/slide_NN.html、 base.css、 assets/ catalog.md、 renders/ 中 Slide Agent 的单页诊断 PNG、 _trace/ 中 Slide Agent 的读取、编辑、渲 染和修订记录。	评价 Slide Agent 是否形成以下闭环：读取页面计划与素材→完成 HTML/CSS/SVG→查看真实渲染 PNG→对照页面目标检查→发现具体问题→修改对应页面→重新渲染确认。这里只评价真实渲染是否被用于驱动修复，不评价最终页面是否美观。	同时满足：1. 所有页面都完成真实渲染检查；2. 检查基于实际 PNG，而不是只阅读 HTML；3. 检查至少覆盖内容容纳、文字或元素遮挡、图片裁切和整体构图；4. 所有被识别为可修改的问题均完成修改；5. 修改后进行了重新渲染；6. 未发现问题的页面也有明确检查记录，而不是笼统声明“页面正常”；7. 没有大量页面在没有自检的情况下直接结束。	大部 查， 验， 部分 修改 记录 题形

评测目标

目标是确认页面生产以真实像素结果为依据，而不是只检查HTML源码。

重点检查：

- 是否读取正式逐页计划和相关资产；
- 是否完成真实渲染；
- 是否检查内容纳入、遮挡、溢出、裁切、比例和构图；
- 是否对发现的问题进行修改；
- 修改后是否重新渲染并复验；
- 没有问题的页面是否也留下具体检查记录。

评价 Slide Agents 是否按照正式逐页计划完成页面，并以真实渲染结果为依据进行局部检查与修复。

重点包括：

- 所有页面是否通过统一派发进入生产；
- 每个 Agent 是否读取自己的逐页计划和相关素材；
- 是否遵守源文件归属；
- 是否完成真实 HTML 渲染，而不是只检查源码；
- 是否检查溢出、遮挡、空白、比例、图片裁切、层级和控制台错误；
- 是否形成具体的“问题—修改—重新渲染—确认”闭环；
- 全局 token 和页面间一致性是否被保持；
- 多 Agent 并行时是否产生冲突或遗漏。

最终产物维度

维度一：多页全局

评估项	评测输入	评什么/定义	1分 (Excellent)	0.5分 (Acceptable)
知识	html提取的内容	reference，该讲哪些具体的点，事实依据；checklist形式0/1，最后求平均，作为这一整个维度的分数	核心知识覆盖完整，事实准确。	
受众与沟通目标适配	html提取的内容	讲给谁听	内容深度、语言和案例高度适合目标受众及使用场景。	整体基本适合受众，但表达较通用，针对性不足。
内容选择与信息密度	html提取的内容+全部渲染图	讲哪些内容	内容取舍准确，重点突出，信息精炼且密度适当。	主要内容合理，但部分页面偏多、偏少或略有重复。
叙事结构与章节过渡	html提取的内容	讲的结构和顺序	主线清晰，章节顺序合理，页面衔接自然。	整体结构可理解，但局部跳跃或过渡生硬。
节奏篇幅与冗余控制	html提取的内容	章节/内容之间的篇幅占比	篇幅与内容重要性匹配，节奏均衡，基本无重复。	整体篇幅尚可，但部分章节失衡或略显拖沓。
跨页语义一致性	html提取的内容	前后内容一致性	术语、数字、定义和结论前后一致。	存在少量表述或口径差异，但不影响主要理解。
全局视觉要求遵循与一致性	全部渲染图	整体视觉的指令遵循和一致性，风格、主题之类的	字体、配色、布局和素材风格的指令遵循和统一，并有合理变化。	整体风格遵循指令并基本统一，但少数页面存在轻微漂移。

维度三：单页

评估项	评测输入	评什么/定义	1分 (Excellent)	0.5分 (Acceptable)
信息层级与密度	html内容 + 渲染图	标题、结论、证据和注释是否层级清楚，信息量是否适当	核心信息突出，层级清楚，阅读顺序和信息量合理。	基本结构清楚，但局部层级较弱或信息稍多、稍少。
图文关系与视觉编码	html内容 + 渲染图	视觉是否真正解释、支持或编码内容，而不只是“相关”	视觉准确解释或支持内容，明显提升理解效率。	视觉与内容相关，但较宽泛、重复或辅助作用有限。
构图、对齐、排版、留白与平衡	渲染图	视觉重心、边距、元素关系、留白和布局是否合理	构图稳定，对齐和分组清晰，留白与视觉重心协调。	布局基本规整，但存在轻微对齐、间距或平衡问题。
字体、颜色、对比与可读性	渲染图	字号、行距、字重、颜色、背景对比是否支持阅读	字体层级清楚，颜色协调，对比充分，文字易读。	整体可读，但局部字号、颜色或对比存在问题。
技术完整性与素材质量	渲染图	是否存在溢出、重叠、裁切、模糊图像、破损资源或异常渲染	无明显溢出、重叠或裁切，素材清晰且正常显示。	存在轻微模糊、偏移或裁切，但不影响核心内容。

第三部分：知识层复用举例

知识来源复用

开放研究型任务可以复用已有DeepResearch benchmark中经过整理的Query和知识rubric，但需要重新映射到演示文稿场景：

- Knowledge检查最终PPT对必要知识的覆盖；
- Research检查Agent是否取得并核验这些知识；
- Plan检查知识是否进入页面规划；
- Deck/Page检查知识是否被有效转化和呈现。

📄 复用案例 1（DeepResearch Bench I）

📄 复用案例 2（DeepResearchBench II）

在开放性的用短query进行research和plan的例子可以复用deepresearch的query和rubric，保证我们知识层的来源的合理性。

实际case rubric

📄 动物环境罗盘 V2.0

目前在复用知识中可以参考的：

Benchmark	任务量	可以复用的核心内容	对PPT
DeepResearch Bench	100	跨22个领域的博士级调研任务，以及任务对应的专业评价标准	最适合做跨领域PPT benchmark的
DeepResearch Bench II	132	长篇grounded research任务、9,430条二元rubric、22个领域	rubric非常细，适合转成PPT中的
ResearchRubrics	101	每题20–43条专家编写评价标准	很适合研究“原领域rubric如何迁
DRACO	100	来源于真实生产场景的复杂研究任务，覆盖10个领域和40个国家	受众和使用场景更加真实，不只是
Dr. Bench	214	专家构造的长篇报告任务，覆盖10个领域	规模较大，适合筛选不同PPT任务
DEER	50	跨13个领域的报告生成任务，以及7个维度、25个子维度、101类细粒度评价项	能帮助定义报告质量和演示质量之
DailyReport	150	日常真实需求驱动的开放式报告任务，包含3,546条rubric，覆盖10个领域、35类任务	适合教学、旅行、健康、消费决策
ReportBench	100	学术survey生成任务，基于高质量综述论文反向构造	很适合迁移成文献综述、组会汇报
DeepResearchEval	100	带persona和真实场景的深度研究任务	可以直接研究同一知识任务面对不
ResearcherBench	65	35个AI研究方向中的前沿研究问题和任务rubric	适合技术调研、学术前沿和科研汇
DeepWeb-Bench	100	六类行业任务，每题按结构化信息矩阵评价	天生适合表格、趋势图、对比图和
DRBench	100	100个企业研究任务、1,093个子问题，覆盖10个企业领域，并区分公开网络和企业内部资料	适合战略汇报、行业分析、竞争分
LiveResearchBench	100	覆盖日常生活、企业和学术研究的动态网络任务	适合需要最新网络信息的PPT任务


第四部分：问题

- 1.现在的知识checklist在评PPT中知识呈现的recall（checklist里面定义的知识点有多少被PPT hit了），但是没有评precision（PPT生成的知识点有多少是正确的，或者是材料中有依据的），或者说这是一个幻觉检测问题。
- 2.混合型任务：用户上传了附件，没有规定PPT一定来自于附件中的内容。

3 混合型任务（附件 + 开放检索）


任务特征：有附件，同时允许外部补充

A Agent 执行时的主要知识来源



在附件基础上，结合外部 research 进行补充与组织

B Benchmark 构建 Query / Rubric 的知识来源



已有 Benchmark 的 Query / Rubric

优质参考 PPT

★ 重点：同时锚定材料知识与开放知识，
兼顾忠实性与扩展性

但是问题是：有附件时附件有啥就用啥，开放型

附录：（最初想法）

现在在做 PPT benchmark 的任务，接下来是我们对 PPT benchmark 任务构建的一个理解。首先，在 PPT 生成任务中，主要包括两个层面的内容，知识层和交付层。然后知识层它需要有一些来源，比如说来源于我的大脑，我自己去编写 query 和 rubric。举个最简单的例子，写一个介绍关于故宫博物院的 PPT。如果以我大脑的知识来写 query 和 rubric 的话，最多写个六七页的内容。那这个时候可能非常了解故宫他能够写一个长城的二三十页的内容。所以说我们要给这个知识一些锚定或者是来源，比如说一些材料，或是别人写好的 PPT，或者是一些文章。那还有就是别人在领域内已经将知识整理好成为 query 和 rubric 的形式，我们也可以直接拿来用。所以我觉得我们不应该再在知识层这个层面再去花大量的功夫，或者是我们去重复造轮子，我们应该在交付层面去打磨。

在 PPT 交付层面上，包括三大部分。第一大部分包括四个点，第一个点是它 PPT 的听众，就是我们向谁说，这会影响到我们的风格，还有我们内容，它的展示层面的一些语言的表达。然后第二个层面，向谁说的基础上，我们要考虑的是压缩这些信息密度和内容，因为我们不可能将知识中所有的内容都呈现在 PPT 上。在压缩内容的基础上，我们还要确定它的一个逻辑展示，比如说在介绍故宫这个 PPT 中，我们从历史说起，然后再到它的布局，最后用它的历史文化地位来作为结尾。在这个逻辑的基础上，我们引入第四点，就是我们对这些每一个逻辑小点到底分给它几页的 PPT 的内容去呈现。这是第一大部分的四点。然后第二大部分就是单页它在内容和视觉上的呈现。单页的内容就是单页内容中逻辑的组织行事和它内容的合理性。然后视觉也分为两个部分，第一个就是我们会搜图和生图，然后通过增加图片的形式，然后去把整个单页的内容或者呈现表达得更合理。第二部分就是整个视觉呈现的，比如说留白、遮挡，或者是它图片的大小这种合理性。这是单页的内容和视觉层面上的。最后一部分就是在长程任务中的一致性。如果我们要做一个 40 到 50 页的 PPT，那后 50 页的内容会不会已经脱离了前 40 页的知识，或者是跟前面这些页数的逻辑有一个很明显的脱节，或者是不一样的地方。这是我理解的交付层面，现在我觉得需要考虑的内容。

设计扣分制的想法：

在设计rubric的时候，对每个评分维度加一个标签："defect_level"，分普通、重大（、致命），然后在评分点时候按照先正常评分得到原始分，然后遍历所有评分点，对重大等级和致命等级的缺陷类型分别处理扣分制：

- 重大等级：如果该评分维度的小点分数=0.5，对应维度总分就扣0.1，0分就扣0.2（几个扣几次，总共最多扣0.5？）
- 致命等级：乘法衰减？如果该评分维度的小点分数=0.5，对应维度总分就乘0.75，0分就乘0.5（0.65和0.3叫做衰减系数，多个致命缺陷就连续相乘？）

对知识层的checklist不需要，不用加这种扣分制

- 第一版只分普通和重大，对于重大细节按照0.1和0.2的扣分制
- 第二版按照前面说的分普通、重大、致命三个等级，完全按照前面说的执行

注意：

1. 不要修改评分点具体内容，只需要加一个标签
2. 对于缺陷等级的选取要合理，不要大部分都打重大或者致命等级，要分析具体的评分内容，严谨一点，对真正重要的评分点才打对应的标签