

MURAL: MULTI-AGENT UNIFIED REVISION-AWARE AUTHORIZING FOR LONG-HORIZON PRESENTATIONS

Anonymous authors

Paper under double-blind review

Chinese author-review draft — formal results pending

ABSTRACT

自动化演示文稿创作是一项长程多模态任务：单页既要内容充实、布局合理，事实、叙事承诺和设计决策还要在整册及后续修改中保持一致。现有 Agent 系统面临责任粒度上的取舍。单条轨迹保留统一上下文，却会持续累积异构执行历史；按功能阶段或单页拆分能够缩短单条轨迹，却把跨边界关系交给多个上下文之间的状态传递与联合验证。我们提出 MURAL，一个将 HTML 演示文稿完整生命周期外置为可复用 Authoring Skill 的技能驱动多智能体框架。Orchestrator 维护 shared deck blueprint，并把具有叙事或视觉依赖的页面编译为 slide groups。每个 Group Agent 联合制作和检查组内页面；页面汇合后由 whole-deck Review 恢复全局闭合；后续修改则按影响范围，从单页、页面组、证据阶段或整册规划处继续执行。我们还提出 THREAD-Bench (Tracking Holistic Requirements and End-to-End Alignment in Decks) 评估长程一致性，并以 PresentBench、SlidesGen-Bench 和 DECKBench 分别补充通用生成与多轮修改评测。工作稿说明：E1–E7 的正式结果仍待完成，本版本不作效果结论。

1 INTRODUCTION

制作一份演示文稿，通常从“讲什么、讲给谁听、希望听众带走什么”开始。作者随后整理附件和已有素材，补充事实与图片，确定叙事结构和设计方向，再把整册目标拆成逐页职责。页面完成后，作者还会从头审看标题链、论证节奏、事实口径和视觉语言，并在交付后根据反馈继续增删、替换或重写内容。现有研究也分别表明，从非连续材料中选择信息、先建立整册 outline，以及依据实际渲染结果修订，都是高质量演示生成不可省略的环节 (Maheshwari et al., 2024; Zheng et al., 2025; Xu et al., 2025)。因此，演示文稿并不是若干页面的一次性拼接，而是一条持续产生、消费和修正决策的创作链。

这条创作链使演示文稿天然具有长程性。受众设定会影响几十页中的术语和信息密度；前页定义的指标、分类或颜色语义，可能直到远处的比较页和总结页才再次出现；开场提出的问题，也需要在结尾得到回应。生成后的修改又引入了版本维度：局部更新既要传播到真正受影响的页面，也要避免破坏无关内容。真实任务评测已经观察到要求遗漏、无依据陈述、数值错误，以及跨页术语或强调关系不一致等问题 (Chen et al., 2026)。本文所说的 long horizon 因而不是运行时间，也不只是页数，而是状态跨阶段、跨页面和跨修订持续有效的距离。我们选择 HTML 作为作者源表示，是因为文本、图形、媒体和布局仍可分别寻址、渲染和修改，并能进一步导出图片、PDF 和 PPTX；复杂 CSS、动画、字体与 PPTX 可编辑结构在转换中的损失，则被明确视为交付边界，而非默认无损。

现有方法暴露出的核心矛盾，不是使用一个还是多个 Agent，而是执行边界与 deck 依赖结构是否一致。单 Agent 沿一条连续轨迹完成整册，可以保留统一上下文和责任主体；但随着页面和修改轮次增加，材料、计划、工具反馈与修订记录也会持续进入同一执行历史。长程 Agent 研究表明，即使尚未触及名义上下文上限，持续增长的历史也可能削弱对早期信息的利用 (Sun et al., 2025)。按功能阶段拆分可以隔离研究、规划、制作和复审，按单页拆分则便于并行生产；但事实沿用、叙事铺垫、视觉编码和开场—结尾呼应往往跨越阶段或页面边界，其共同责任仍要依靠跨上下文交接和事后验证维持。这里并非断言单 Agent 必然遗忘或逐页 Agent 必然漂移，而是指出：只有当责任边界与实际依赖相符时，任务拆分才




Figure 1: 三种页面生产拓扑及其责任边界。顺序式生成让状态沿持续增长的历史推进；full-context parallel 将相同的 deck context 复制给各自负责一页的 worker。MURAL 外化 shared deck blueprint，按跨页依赖编译 group briefs，并由同一 Group Agent 联合生成和检查相关页面。三者的区别不在是否拆分或最终装配，而在共同责任放在哪里：MURAL 在汇合前闭合组内关系，再由 whole-deck Review 验证跨组关系。

会减少协调负担。通用 Agent 研究同样发现，多 Agent 的效果取决于任务可分性、共享信息和验证位置，而不只是 Agent 数量 (Kim et al., 2025)。

由此产生的关键问题是：谁应当对一组跨页关系共同负责？给每个页面 worker 复制完整 deck context，并不会自动形成共同责任；把相邻页面按固定窗口分块也不充分，因为封面与结尾、各章过渡页、跨页对比或同一视觉素材系列可能并不相邻。我们在整册与单页之间引入 slide group 作为生产责任单元。Orchestrator 依据叙事职责、设计 DNA、素材系列和显式依赖，把所有页面编译为完整且不重叠的 groups；组内共享决策和检查责任，但不要求复用同一种几何模板。我们将其称为**依赖对齐的责任拓扑**：组内关系由同一 Agent 在一条有界轨迹中闭合，无依赖 groups 可以并行，后续修改则只重新激活最小的可靠责任单元。多 Agent 在这里不是贡献本身，而是实现这种责任拓扑的执行机制。

MURAL 以这一责任拓扑把完整生命周期外置为 MURAL Authoring Skill。Orchestrator 解析受众、目的和交付约束，按需启动 Material 与 Research，随后确定整册故事线、设计系统、page map、逐页 brief、资产板和 production groups。需要位图时，一个集中 Image 阶段先完成全册素材解析与审校，再开放页面生产。每个 Group Agent 联合完成所辖页面，并通过组级 render-inspect-revise 循环检查组内叙事、视觉语义和节奏；所有 groups 汇合后，whole-deck Review 再处理跨组的事实、叙事、设计与任务要求。Figure 1 对比顺序式、完整上下文逐页并行和 MURAL 的 group-parallel 拓扑。这一 Skill 不只是提示模板，而是对阶段、角色、输入、落盘产物、质量门和继续执行路径的可执行描述。

同一套持久状态也把生成后的修改纳入 authoring lifecycle。可精确定位且不改变共享系统的请求，由 Orchestrator 直接修改对应页面并局部重渲；涉及同组多页关系或组内视觉语言时，系统重新激活完整 Group Agent；新增事实或素材时，再补充必要的 Research 或 Image；章节、页数、标题链或多个 groups 变化时，才重规划受影响结构并复审整册。增页、删页和移动页面因此不是孤立的 HTML patch，而是结构性 revision。生成阶段保留的 inspect-diagnose-patch-rerender 轨迹，可能在没有单独 revision-only 训练的情况下迁移为编辑能力，但这只是待验证假设。本文将用修改成功率、指令遵循、未修改页面保持和回归错误来检验，而不把成品结构的 editability 等同于 Agent 的修改能力。

为训练和评估这一能力，我们设计了一条可控的 long-horizon agentic data 管线：Query-Generator 组合 domain、style、audience、speaker perspective、purpose、language 和材料条件，并注入可检查的跨页要求；候选 rollout 保留 planning、delegation、render inspection 与 refinement，只有通过质量门的完整轨迹才进入 SFT。评测方面，THREAD-Bench 同时检查过程证据、知识准确性、整册与单页表现，并以 case-specific probes 诊断远距离关系；PresentBench 与 SlidesGen-Bench 补充材料接地、内容、美学和成品结构评测，DECKBench 则用于多轮修改。本文的贡献概括如下：

1. 提出一个覆盖研究、规划、分组制作、两级检查、生成后修改和多格式交付的 Skill-defined presentation authoring lifecycle;
2. 提出一种依赖对齐的多智能体责任拓扑, 以 slide group 共同负责关联页面的生成、检查和修订, 同时保留组间并行与按影响范围的选择性重执行;
3. 提出 THREAD-Bench, 从过程与成品两侧评估长程创作, 并结合通用生成与多轮编辑 benchmark 系统分析 MURAL。

2 RELATED WORK

2.1 PRESENTATION GENERATION ACROSS THE DECK LIFECYCLE

早期文档到演示文稿系统主要研究内容选择、摘要和页面组织。演示叙事需要从分散材料中选择信息并重新组织, 而非把连续文本压缩为页面 (Bandyopadhyay et al., 2024; Maheshwari et al., 2024)。后续 Agent 系统逐渐覆盖更多生命周期阶段。PPTAgent 通过参考页面与 outline 显式规划整册结构, PreGenie 在中间代码和渲染页面上执行多阶段复核 (Zheng et al., 2025; Xu et al., 2025); SlideBot 由中心角色组织检索、规划、代码生成与增强, DeepPresenter 则把 Researcher、Presenter、共享环境和渲染后的反思连接起来 (Xie et al., 2026; Zheng et al., 2026)。这些工作说明 planning、专职角色、共享文件和 render-aware revision 已是重要基础。MURAL 的区别不在于把这些阶段再次拆成更多子任务, 而在于用 shared blueprint 连接完整生命周期, 并按跨页依赖定义生产责任和后续重执行边界。

2.2 LONG-HORIZON STATE AND MULTI-AGENT GRANULARITY

长程 Agent 的困难既来自历史增长, 也来自状态如何外化和分配。Context Folding 表明, 持续累积的执行历史会影响已有信息的利用 (Sun et al., 2025); LongHorizon-Harness 则把经环境验证的任务状态外置, 并以 manager、fresh-context executor 和 read-only auditor 交替推进通用电脑任务 (Ma et al., 2026)。多 Agent 的受控研究还表明, 任务可分性、信息共享和验证位置会显著改变结果 (Kim et al., 2025)。这些工作共同支持显式状态和独立验证, 却没有回答演示文稿应以什么边界组织页面生产。MURAL 关注的是哪些远距页面关系需要共同负责者: 页面组同时作为联合生成、检查和后续修改的责任单元, 跨组关系再由 whole-deck Review 闭合。

2.3 AGENTIC DATA, REFINEMENT, AND REVISION

Agent tuning 已从仅学习最终回答, 扩展到保留任务分解、工具调用和多步交互的轨迹 (Zeng et al., 2024; Chen et al., 2024)。迭代反馈与修订也被证明能够在生成过程中逐步改善输出 (Madaan et al., 2023)。MURAL 的训练数据进一步保留渲染检查、问题诊断、补丁与重渲行为, 因此属于 agentic SFT, 而非输入到最终 deck 的 output-only SFT。不过, 生成期 refinement 是否会自然迁移为生成后的编辑能力, 不能由轨迹形式本身推出。我们把它作为独立实验问题, 通过移除 refine 轨迹和控制 base model/SFT 数据来辨别收益来源。

2.4 PRESENTATION GENERATION AND EDITING BENCHMARKS

现有 benchmark 从不同角度评估完整演示文稿。PresentBench 对材料约束任务进行细粒度原子检查; SlidesGen-Bench 在统一渲染表示上评估 Content、Aesthetics 与 Editability; DECKBench 同时覆盖学术 deck 生成和多轮编辑 (Chen et al., 2026; Yang et al., 2026; Jang et al., 2026)。其中 SlidesGen-Bench 的 Editability 描述成品结构, 而非 Agent 根据指令完成连续修改的能力。PPTArena 评估已有 deck 上的复合与跨页编辑, PPT-Eval 则以 PowerPoint 原生交互任务检查创建、编辑、部分完成和不必要改动 (Ofengenden et al., 2025; Gandhi et al., 2026)。LH-Bench 也已用 Skill-grounded rubric 联合评估 Agent harness 的过程和产物 (Gupta & Chandwani, 2026)。THREAD-Bench 因此不声称首次评估长文档、Skill 或跨页编辑; 其定位是面向从零创作完整 deck 的生命周期, 把过程证据、成品质量和 case-specific 长程关系放在同一评测中, 并按 dependency span 分析关系闭合。

3 长程 AGENTIC 数据合成

3.1 从结构化 QUERY 出发，而不是只给一个主题

QueryGenerator 构造结构化 specification，而不是只采样主题。它组合领域、风格、语言、目标页数、材料、受众、目的和演讲者视角，再加入 2-4 条可检查的跨页要求，例如复用同一定义、延续视觉编码，或在远处回应开场问题。这样，长程状态在轨迹生成前就是任务的一部分。

当前 inventory 包含 1,000 条互异 specification (中文 850、英文 150)，受控池包含 22 个顶层领域文件、306 个不重复叶节点和 43 种风格。这些数字描述 query inventory，不代表真实流量分布或 accepted training yield。我们区分 N_{query} 、 $N_{rollout}$ 、 $N_{complete}$ 和 $N_{accepted}$ ：一条 query 可产生多条 rollout，流程完成也不等于被接收。

3.2 双模型 ROLLOUT 与轨迹验收

计划中的 DeepSeek-V4-Flash 与 Gemini-3.5-Flash rollout 执行同一 MURAL Authoring Skill。除最终 deck 外，它们还留下 material/knowledge briefs、shared blueprint、group/page briefs、素材、HTML、contact sheets、Review 结论与 patch；endpoint、分配、采样与最终 mixture 留待 release freeze。

确定性 gate 检查必需产物、页面覆盖、构建和渲染；rubric 检查指令满足、知识接地与可见缺陷；去重限制近似样本。失败或不可核验轨迹仍计入账本，但不被改写为 accepted data。冻结版本会报告四类计数和拒绝原因。

被接收样本保留规划、委派、工具调用、渲染检查、诊断、patch 和重新渲染，因此属于 **agentic SFT**：监督对象是可执行 authoring trajectory，而不只是最终 HTML。它不是专门的 editing corpus，但 refinement turns 包含后续修改会用到的操作。E5 与 matched-data 消融检验这类监督能否迁移到多轮修改，并保持未涉及页面；在此之前，refinement 只是待验证假设，不是编辑能力的既定原因。

4 MURAL

4.1 任务与长程状态

长 deck 要求事实、术语、叙事铺垫和视觉编码在远距离页面中继续成立，同时每页仍需根据自身职责组织内容与版式。MURAL 的设计目标不是增加 Agent 数量或最大化并行度，而是让执行责任与这些依赖的作用范围一致。系统将整册决策记录为持久状态，把关联页面交给具有共同责任的生产单元，并在装配后验证跨单元关系；页数本身不是研究目标。

给定用户 brief q 、附件 $\mathcal{M}$ 、语言 ℓ 和页数 N ，系统生成 deck $D = (s_1, \dots, s_N)$ 、讲稿 $U = (u_1, \dots, u_N)$ 、渲染结果与轨迹 Π 。共享整册状态 G 保存事实与来源、术语、叙事关系、视觉 token 和交付要求。长程依赖记为 $g_k = (a_k, T_k, \Phi_k)$ ：源页面 a_k 建立一项决策，目标集合 T_k 必须消费或回应它， Φ_k 检查对应关系。整册依赖闭合率为

$$DC(D) = \frac{1}{K} \sum_{k=1}^K \mathbf{1} \left[\bigwedge_{t \in T_k} \Phi_k(s_{a_k}, s_t) = 1 \right].$$

该定义把单页质量与决策的持续有效性区分开来。Production groups 构成页面的完整、不重叠划分；当 $\{a_k\} \cup T_k$ 位于同一 group，依赖由一个 Group Agent 负责，否则由 shared blueprint 与 whole-deck Review 连接。系统不把所有页面并为一个大 group，以免重新形成无界轨迹。

4.2 SKILL 定义的生命周期

MURAL Authoring Skill 统一定义阶段触发、角色输入、落盘产物、质量门和修改路由。Material 整理可选附件，Research 接地知识，Orchestrator 维护状态并委派，Image 解析素材，Group Agent 制作关联页面，Review 恢复整册判断。runtime 只提供工作区、并发与轨迹；创作决策保存在显式产物中，而非对话历史里。




Figure 2: **MURAL** 的完整创作与修改生命周期。Material 与 Research 完成输入接地，Orchestrator 将整册决策外化为 shared deck blueprint 和 group briefs。统一的 Image 阶段准备素材，多个 Group Agent 再并行闭合各自的 render-inspect-revise 循环。确定性装配恢复整册视图，供 whole-deck Review 检查。Review 与人工修改共用 revision router：局部请求定向修改单页，跨页请求重新激活相关 group，只有整册结构变化（包括增删页面）才回到规划阶段，最后导出 HTML、PPTX、PDF 与图片。

Research 从用户 brief 与可选材料中记录论点、证据和来源；Orchestrator 确定受众、故事线、术语、设计语言、页面职责和素材策略。集中 Image 阶段把选择记录到 `assets/catalog.md`；版本化的 `deck.py fetch-images` 负责下载与校验，模型侧没有自定义 `fetch_image` 工具。

图 2 概括了从接地与规划、分组制作、整册复审，到按范围修改和多格式交付的完整生命周期。

4.3 SHARED BLUEPRINT 与依赖对齐的责任拓扑

Orchestrator 将全局决策外化为 shared deck blueprint。plan/deck.md 保存证据、叙事、术语、设计系统、page map、资产和 groups；plan/slide_NN.md 投影每页所需状态。验证再编译 theme tokens、base.css、skeleton 和讲稿。各 Group Agent 共享同一事实与设计来源，却不继承其他 groups 的执行历史。

页面组是介于单页和整册之间的责任单元。Orchestrator 不按阶段、页码或固定窗口机械分割，而按叙事职责、setup-response、设计 DNA、素材和显式依赖分组。当前实现把封面与结尾放在同一 bookends group，把章节过渡页归为同组，内容页则按连续论证与设计亲缘性组织。groups 可以连续、非相邻或为单页；共同责任不等于共用模板。

因此，Agent 只维护本组的有界轨迹，组内关系具有共同生产与检查者，group 也成为后续修改的重执行边界。组间并行是这些边界的结果，而非首要论点。

4.4 分组并行制作与两级闭环

每个 Group Agent 接收 blueprint、briefs、skeleton 和素材，在一条有界轨迹中联合生成本组页面，渲染 group contact sheet，合并缺陷并复验。组间通过 blueprint 和落盘产物协调，而非频繁协商；互不重叠的源文件责任允许安全并行。

各组汇合后，确定性 finalize 检查连续性、装配权威 HTML，并生成 whole-deck contact sheet。Review 检查事实口径、术语、setup/response、视觉语义和节奏；问题被返回给最小可负责单元，修复后重新 finalize 并复查整册。

4.5 修改路由与交付

生成后的请求复用同一状态。local_revision 修改单页，group_revision 重新激活 Group Agent，evidence_revision 补充 Research 或 Image，global_revision 为增删页、换序等结构变化更新 blueprint 和 groups；范围不明时升级一级。该路由限制计划中的重放范围，其质量与未修改页面保持由多轮实验验证。

验收后的结构化 HTML/CSS/SVG 可导出为 HTML、PNG、PDF 和 PPTX。这些适配器共享同一创作源，但具有不同的保真度与可编辑性边界，论文将其与生成质量分开报告。

5 THREAD-BENCH

5.1 缺失的可观测量与样例构造

一份演示可以在第 3 页规定“蓝色表示已确认、灰色表示待核验”，到第 18 页却悄然交换两种颜色的含义。两页单独看都可以成立，整套 deck 仍然不可交付，因为前页建立的设计决定没有在指定后页得到遵守。事实口径、术语、待回答问题和任务要求也会产生同类失配。THREAD-Bench 因而把 source 页面与一个或多个 target 页面之间的关系直接写入评测规范，使状态从建立到再次使用的过程成为可定位、可按距离统计的对象。

当前设计目标为 50 个专家构造的完整 deck 任务，分为 visual system、narrative logic、cross-slide state、grounded synthesis 和 constraint coordination 五个 suite，每个 suite 计划包含 10 个 case。等量划分只用于覆盖核验，不表示真实任务或能力彼此互斥。cases 会覆盖不同页数、语言、材料条件与约束密度；它们是定向压力测试，而不是从真实用户流量抽样。

每个 case 保存用户 brief、可选冻结材料、预期交付格式、可验证 requirements、长程 dependency probes，以及能够定位到页面的证据规则。准确的页面总数、语言/材料分布、core/challenge 划分和派生 requirement/dependency 计数，都属于 release manifest 字段。本工作稿不把当前 inventory 写成冻结统计；只有 canonical case index 与材料完成冻结后，正文才报告这些数字。

5.2 REQUIREMENTS、DEPENDENCIES 与 HORIZON

每个 case 把可验证的 must requirement 与非否决性的 should preference 分开。must 进入可交付硬门，因此指定页数、必备事实或禁用设计不会被较高的主观质量分数抵消。deck-level must-requirement satisfaction 是共同主要终点之一；两类要求的最终计数从冻结 manifest 生成，不沿用草稿 inventory 数字。

Dependency 描述一项状态在 deck 中的去向。一个 probe 从 source 页面建立事实、术语、问题—回应关系、视觉编码或任务决定，并指定一个或多个必须继续使用或回应它的 target 页面；只有全部 target 都正确，才记为闭合。若 source 和 target 的页码分别为 s 与 t ，跨度定义为

$$d = t - s.$$

逐 target 的判断显示具体失效位置，逐 probe 的 closure 则要求所有目标同时成立。release report 会从冻结 case index 重新计算 1-4、5-9、10-14 和 15+ 页四个 span 区间。两种口径都先在 case 内聚合，避免依赖较多的长任务自动获得更大权重。

自然形成的 medium、long 与 ultra 切片同时改变主题、内容密度和要求组合，只用于描述完整任务上的失效分布。E2 另从 anchor cases 派生内容匹配的 10/20/30/40 页变体，在固定核心事实、dependency 类型和预算规则的条件调整 source/target 布局；只有这组 matched families 支持更强的 horizon 解释。页数与 span 无法正交时，结果明确标为联合效应。

5.3 指标、报告口径与复现边界

THREAD-Bench 不发布加权质量总分。共同主要终点为 deck-level must requirement satisfaction 和 dependency-group closure；deployable_as_is 是更严格的联合终点，要求生成完成，并通过全部适用 hard gates 和 must requirements。诊断结果进一步报告按 span 的 target accuracy，以及事实/数值、术语/状态、叙事逻辑与视觉编码四类一致性。八个 1-5 质量轴继续保持独立。完成、失败、超时和不可核验数量均保留在全部 50 个 case 的分母中；质量轴同时给出 all-case 与 conditional-on-completion 口径，后者不能替代主结果。

Judge 对 requirement 和 dependency 的判断必须附带可定位到页面的证据，一致性类型也随同保存。E7 在独立校准集上由至少两名人工标注者检验 inter-human 与 human-Judge

agreement; 通过门槛之前, Judge 输出不能进入主要结论。benchmark index 记录 case 与 schema hash, material manifest 记录材料 hash; Judge prompt、rubric、模型和聚合代码在 E0 的系统比较 manifest 中另行冻结。污染审计只覆盖可以获得的数据源, 训练语料不可见时不作 zero-contamination 声明。当前任务设计偏规格化, 更自然的 brief 与隐藏验收项留作后续扩展。

6 EXPERIMENTS

6.1 研究问题与公共协议

RQ1 检验通用质量、整册要求与 dependency closure; RQ2 分析 span/horizon; RQ3 定位一致性失败; RQ4 区分一般拆分与 dependency-aligned ownership、共享状态和两级检查; RQ5 检验修改、保持与 replay scope; RQ6 校准 Judge。运行时间、token 和成本只作次要指标。

比较统一 backbone、temperature、输入、renderer、预算、重试上限、失败规则及每 case 3 个 seed。seed 按预注册规则在 case 内聚合, case 是最高层分析单位。paired bootstrap 先重采样 case、再重采样其 seed, 报告双侧 95% CI; 共同主要比较使用 Holm 校正。缺失 artifact、失败和超时保留在分母中; 失败输出仍适用的质量轴固定记为 1, N/A 与 scored coverage 单列。不可控闭源产品只作参考。

6.2 E0: REPRODUCIBILITY FREEZE

E0 冻结候选系统、50 个 case、E2 anchors、E7 独立校准集, 以及代码/Skill、renderer、backbone、推理参数、预算、seed、失败规则和 Judge/聚合版本。benchmark、materials、“THREAD-Bench evaluation spec”与“MURAL system-comparison protocol”分别记录 hash, 任一不符即停止执行。并发、Clean Skill 选择和 thinking/effort 只用于复现。168791d...是当前候选 Skill snapshot; 已有 runtime、特殊页与 role/runtime 检查不能表示完整实验栈已锁定。

6.3 E1: 通用质量与完整 DECK 主比较

E1a 按官方协议在 PresentBench 与 SlidesGen-Bench 上报告内容、材料接地、美学和成品结构; 外部系统另表呈现, 并披露模型、预算、renderer 与格式差异。

E1b 在 THREAD-Bench 全部 50 个 case 上比较: (1) 单 Agent 全生命周期; (2) 无 dependency-aware groups 的 stage-specialized Agents; (3) 共享同一 blueprint 的 full-context per-slide workers; (4) MURAL group ownership。四者匹配 backbone、输入、renderer、工具和总预算, 例外项单列, 从而区分一般拆分与责任边界对齐。

输出通过 deterministic checks 后交给不知道系统身份的冻结 Judge。Table 2 报告 PresentBench 与 SlidesGen-Bench; Table 3 报告 must-requirement satisfaction、dependency closure、deployable-as-is、span accuracy、四类一致性、八轴质量、完成率、页数遵从性与 scored coverage。结论只适用于冻结的 release、backbone、预算和 benchmark。

正式主比较尚未完成: TBD-E1。

6.4 E2: DEPENDENCY SPAN 与 DECK HORIZON

E2a 报告 target accuracy 随 dependency span 的 case-balanced 曲线, 至少覆盖 1-4、5-9、10-14 和 15+ 页, 并在样本允许时按 dependency type、位置和系统分层。自然 case 的内容差异使其只支持完整任务上的关联。

E2b 从至少 6 个 anchors 派生 10/20/30/40 页 matched families, 并尽量交叉 short/long span。核心事实、dependency 类型、内容块、视觉系统和预算规则固定, 只调整布局及维持篇幅的内容。分析 system、pages、span 和预注册交互项, 采用 family-cluster bootstrap 与 family 内随机化检验。无法正交构造时只报告联合效应; Figure 3 展示 closure、target accuracy、一致性和配对区间。

依赖距离与 matched-family 估计尚未完成: TBD-E2。

6.5 E3: 一致性与失败类型

E3 预注册事实/数值漂移、术语/状态冲突、叙事铺垫/交接/闭合失败、视觉/整册规则漂移、要求遗漏、unsupported grounding 和渲染/artifact 失败。一个 target 可保留多标签，但“任一失败”与各类型分别报告。

分析给出 case-level rate、首次出现位置、span、早/晚 target 与类型共现。Figure 4 将代表性 source/target 与 Judge 页面证据配对，用于定位 horizon，而不作模块因果归因。

失败类型分析尚未完成：TBD-E3。

6.6 E4: 责任拓扑与生命周期机制

E4 将 Agent 数量与责任边界分开。50-case topology panel 包含：(1) 保留 blueprint 与 whole-deck Review 的 per-slide ownership；(2) 规模匹配、但只按页码切分的 fixed-adjacent groups；(3) 以逐页检查替代组图检查的 no group-joint inspection；(4) local-only Review。size-matched random groups 仅在固定 10-case 子集按预注册划分诊断。

固定子集上的 lifecycle panel 测试 Generic Skill、No shared blueprint/group brief 和 No Review，分别替换角色化说明、移除整册 source of truth 或跳过装配后复核。每个变体只改变一个因素；同时改变拓扑、工具、上下文和检查预算的比较不能概括为“有无多 Agent”或“有无 Skill”。

matched-data panel 比较 final-artifact SFT、移除 inspect-diagnose-patch turns 的 agentic trajectories 与完整 accepted trajectories，并固定 query IDs、accepted-example 数量、优化 token、base model 和训练 recipe。E1 检查生成影响，E5 检查修改迁移；若编辑成功率提高却破坏未涉及页面，则不算成功迁移。

Table 5 报告 requirements、总体及 within-/cross-group closure、span-conditioned accuracy、四类一致性、deployable-as-is 与 completion。检查变体报告 repair/regression rate；后者以检查前正确且可复核的机会为分母。组内收益与跨组损失必须分开呈现。

拓扑、生命周期与数据监督消融尚未运行：TBD-E4。

6.7 E5: 多轮修改与选择性重执行

E5 在 DECKBench 上从同一初始 deck 和请求序列比较 scope-aware routing、local-only routing 与每轮 full-deck replay，并报告逐轮/整段成功、指令遵循、一致性、untouched-slide preservation、新增 regression、replay scope 和重启阶段。HTML 转换失败与不可编辑元素单列；replay scope 验证选择性重执行，但不代替修改质量。

多轮修改实验尚未运行：TBD-E5。

6.8 E6–E7: 系统核算与 JUDGE 校准

E6. E1、E2、E4 和 E5 记录 wall-clock、critical path、调用、tokens、费用、peak context/overlap、render/view、worker duration 与三类并发。workspace snapshot 区分模型 write_file/patch 与 terminal/deck.py 文件变化。它们只进入附录的次要系统核算，不进入摘要主结论 (TBD-E6)。

E7. E1 前，至少两名标注者在与 E1 输出无重叠的冻结集上独立判断 requirements、dependencies、一致性和质量轴，再锁定 Judge、证据格式与阈值。E1 后的 held-out 审计只估计误差，不修改 prompt、rubric、阈值或既有分数。二元标签报告 nominal α/κ ，1–5 轴报告 ordinal α 或 weighted κ ；低一致性维度降级为探索性 (TBD-E7)。

Legacy-Release Trace Audit. Pilot B 复用无新增模型调用的旧轨迹；其中的 plan/pages.json、research_01 与旧 scaffold 不能验证当前工作流，只说明持久轨迹可暴露 worker 区间、文件读取与成品问题。附录统计不是当前 release 的质量或 long-horizon 证据。

7 DISCUSSION AND LIMITATIONS

页面组让责任更加明确，但多 Agent 数量本身不构成收益，效果取决于 Orchestrator 能否识别正确的依赖边界。错误分组可能拆开本应共同负责的关系，或形成过大的轨迹。遗漏和持续变化的跨组依赖仍需 whole-deck Review 发现；高度耦合的动画与复合图也未必适合不重叠的责任划分。

当前 1,000 条数据是 query specifications，而不是 accepted trajectories；rollout 产率、过滤偏差和训练收益仍待测量。合成约束可能偏向容易表述与验证的要求，而低估受众默契等隐性目标。消融需区分 query 多样性、被接收轨迹的质量和 refinement 监督本身。

THREAD-Bench 仍是专家压力测试：grounding 有限，matched families 尚不完整，Judge 也需要校准；准确 inventory 在 release manifest 冻结前仍属 provisional。HTML 及其导出适配器也限制外推。因此，E1-E7 必须同时报告修复与回归，并用 dependency closure 而非运行时间或成本判断有效性。

8 CONCLUSION

MURAL 将演示文稿视为持续创作生命周期。它不只拆分更多子任务，而是让生产与重执行边界对齐 deck 依赖。Shared blueprint、页面组、两级复审和按范围修改维护跨页面与版本的决策；THREAD-Bench 检验这些依赖能否在更长 horizon 下闭合。

REFERENCES

- Sambaran Bandyopadhyay, Himanshu Maheshwari, Anandhavelu Natarajan, and Apoorv Saxena. Enhancing presentation slide generation by LLMs with a multi-staged end-to-end approach. In *Proceedings of the 17th International Natural Language Generation Conference*, pp. 222–229, Tokyo, Japan, 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.inlg-main.18. URL <https://aclanthology.org/2024.inlg-main.18/>.
- Xin-Sheng Chen, Jiayu Zhu, Pei-lin Li, Hanzheng Wang, Shuojin Yang, and Meng-Hao Guo. Presentbench: A fine-grained rubric-based benchmark for slide generation. *arXiv preprint arXiv:2603.07244*, 2026.
- Zehui Chen, Kuikun Liu, Qiuchen Wang, Wenwei Zhang, Jiangning Liu, Dahua Lin, Kai Chen, and Feng Zhao. Agent-flan: Designing data and methods of effective agent tuning for large language models. In *Findings of the Association for Computational Linguistics: ACL 2024*, pp. 9354–9366, 2024.
- Apurva Gandhi, Vishwas Suryanarayanan, Raja Hasnain Anwar, Firoz Shaik, Shubhang Desai, Thong Q. Nguyen, Muhammad Taqi Raza, Vishal Chowdhary, and Graham Neubig. PPT-Eval: A benchmark for computer-use agents on PowerPoint tasks. In *Forty-third International Conference on Machine Learning*, 2026.
- Ishan Gupta and Abhishek Chandwani. LH-Bench: Skill-grounded evaluation of long-horizon agents on subjective enterprise tasks, 2026. URL <https://arxiv.org/abs/2603.22744>. arXiv:2603.22744v2.
- Daesik Jang, Morgan Lindsay Heisler, Linzi Xing, Yifei Li, Edward Wang, Ying Xiong, Yong Zhang, and Zhenan Fan. Deckbench: Benchmarking multi-agent frameworks for academic slide generation and editing. *arXiv preprint arXiv:2602.13318*, 2026.
- Yubin Kim, Ken Gu, Chanwoo Park, Chunjong Park, Samuel Schmidgall, A. Ali Heydari, Yao Yan, Zhihan Zhang, Yuchen Zhuang, Mark Malhotra, Paul Pu Liang, Hae Won Park, Yuzhe Yang, Xuhai Xu, Yilun Du, Shwetak Patel, Tim Althoff, Daniel McDuff, and Xin Liu. Towards a science of scaling agent systems. *arXiv preprint arXiv:2512.08296*, 2025. URL <https://arxiv.org/abs/2512.08296>.
- Ziyu Ma, Hailang Huang, Shun Zou, Yong Wang, Shidong Yang, Yiming Hu, Fei Wei, and Xiangxiang Chu. LongHorizon-Harness: Advancing long-horizon agents for real-world tasks, 2026. URL <https://arxiv.org/abs/2608.01964>. arXiv:2608.01964v1.
- Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wierffe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdanbakhsh, and Peter Clark. Self-refine: Iterative refinement with self-feedback. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- Himanshu Maheshwari, Sambaran Bandyopadhyay, Aparna Garimella, and Anandhavelu Natarajan. Presentations are not always linear! GNN meets LLM for text document-to-presentation transformation with attribution. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pp. 15948–15962, Miami, Florida, USA, 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.findings-emnlp.936. URL <https://aclanthology.org/2024.findings-emnlp.936/>.
- Michael Ofengenden, Yunze Man, Ziqi Pang, and Yu-Xiong Wang. PPTArena: A benchmark for agentic PowerPoint editing. *arXiv preprint arXiv:2512.03042*, 2025. URL <https://arxiv.org/abs/2512.03042>.
- Weiwei Sun, Miao Lu, Zhan Ling, Kang Liu, Xuesong Yao, Yiming Yang, and Jiecao Chen. Scaling long-horizon LLM agent via context-folding, 2025.
- Eric Xie, Danielle Waterfield, Michael Kennedy, and Aidong Zhang. Slidebot: A multi-agent framework for generating informative, reliable, multi-modal presentations. In *AAAI Conference on Artificial Intelligence (AAAI)*, 2026.

- Xiaojie Xu, Xinli Xu, Sirui Chen, Haoyu Chen, Fan Zhang, and Ying-Cong Chen. PreGenie: An agentic framework for high-quality visual presentation generation. In *Findings of the Association for Computational Linguistics: EMNLP 2025*, pp. 3045–3063, Suzhou, China, 2025. Association for Computational Linguistics. doi: 10.18653/v1/2025.findings-emnlp.165. URL <https://aclanthology.org/2025.findings-emnlp.165/>.
- Yunqiao Yang, Wenbo Li, Houxing Ren, Zimu Lu, Ke Wang, Zhiyuan Huang, Zhuofan Zong, Mingjie Zhan, and Hongsheng Li. SlidesGen-Bench: Evaluating slides generation via computational and quantitative metrics. *arXiv preprint arXiv:2601.09487*, 2026. URL <https://arxiv.org/abs/2601.09487>.
- Aohan Zeng, Mingdao Liu, Rui Lu, Bowen Wang, Xiao Liu, Yuxiao Dong, and Jie Tang. Agenttuning: Enabling generalized agent abilities for llms. In *Findings of the Association for Computational Linguistics: ACL 2024*, pp. 3053–3077, 2024.
- Hao Zheng, Xinyan Guan, Hao Kong, Wenkai Zhang, Jia Zheng, Weixiang Zhou, Hongyu Lin, Yaojie Lu, Xianpei Han, and Le Sun. Pptagent: Generating and evaluating presentations beyond text-to-slides. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 14402–14418, 2025.
- Hao Zheng, Guozhao Mo, Xinru Yan, Qianhao Yuan, Wenkai Zhang, Xuanang Chen, Yaojie Lu, Hongyu Lin, Xianpei Han, and Le Sun. Deeppresenter: Environment-grounded reflection for agentic presentation generation. *arXiv preprint arXiv:2602.22839*, 2026.

A 附录草稿

复现台账。 168791d20585d3d7a667540215736c4b639a2458 作为当前候选 Skill snapshot, 与关键文件哈希、已有 regression checks 和 special-page smoke test 一并保留; 它尚不表示完整实验栈已经冻结。台账还记录 Clean Skill 选择、thinking/effort、三类独立并发控制与 catalog 驱动的 fetch-images 脚本。正式 baseline 配置、renderer 与模型设置、canonical benchmark manifests、Judge prompt、人工标注协议和完整逐 case 结果, 只有在 E0 锁定后才补齐。

次要系统核算。 Wall-clock time、critical-path duration、调用、tokens、估算成本、context overlap、render 次数和三类并发控制仅用于复现与部署核算。这些指标不是 long horizon 的定义, 也不能替代主分析中的 deck-level requirement satisfaction、dependency closure 或四类一致性指标。

Pilot 的解释边界。 本工作稿不把 provisional benchmark inventory counts 作为证据。Pilot B 只把审计代码应用于旧版 release 的持久化轨迹; 它不是生成质量的受控比较, 也不能验证当前 grouped workflow。

A.1 PILOT B: 旧版发布轨迹审计

Pilot B 复用两个已完成运行, 未产生新模型调用。两者都包含 plan/pages.json、分片 research_01 与旧版 scaffold 契约, 早于当前 Markdown-plan candidate。grouped workflow 由 Orchestrator 写出 plan/deck.md 与 plan/slide_NN.md, 再由 scaffold-from-plans 确定性生成轻量 HTML skeleton 与讲稿。按页面生成器首事件至 trace completion 计, 3 页运行的 wall/worker-sum 为 407.272/759.235 秒, 并行压缩 1.864×、峰值并发 3、符合当时读取说明的页面生成器为 3/3; 6 页运行分别为 369.030/1049.931 秒、2.845×、6 和 5/6。后者的 slide_05 读取过 slide_03.html; 持久化 tool log 未记录 peer/shared 的直接源文件写入。审计不能观察 provider 隐藏上下文或 terminal action 引起的文件变更, 也不证明当前 release 的执行边界、质量或相对节省。

两次运行分别记录 73/151 次调用与 1.93M/6.44M input tokens。6 页任务明确禁用默认奶油白, 但完成 Review 后仍在 base.css 使用 #ede2cc/#e2d3b3。该单例不能估计失败率, 却表明 completion、渲染与边界符合不能替代 E1 的 requirement judge。当前 release 的边界陈述来自静态代码检查, 真实执行遵从性仍须由 E0 之后的新轨迹检验。

Pilot 产物。 机器可读旧轨迹统计保存在 `pilot_b_trace_audit.json` 与 `pilot_b_worker_intervals.csv`。受限的 `source/contact-sheet` 检查记录在 `pilot_b_output_sanity.md`, 其中同时保留 `source hashes`。